

BEYOND 99% ACCURACY

A Cross-Dataset Audit of NLP + SVM Phishing-URL Detection on the PhiUSIL Benchmark

UAS Kecerdasan Buatan

[Nama] — [NIM] — [Universitas]

phishing detection · dataset bias · generalization

Latar Belakang & Masalah

2

- Phishing = ancaman siber paling masif (≈ 1 juta insiden/kuartal, APWG).
- Deteksi URL berbasis ML jadi pertahanan standar.
- Dataset PhiUSIIL (235.795 URL, 56 fitur) jadi benchmark populer.
- Banyak studi melaporkan akurasi $>99\%$ di dataset ini.

99.99%

akurasi yang dilaporkan paper acuan
(AUC = 1.0)

*Sempurna untuk deteksi phishing dunia nyata?
Patut dicurigai.*

Jurnal Acuan: Aritonang dkk. (2026), JUTIF

3

Metode: NLP (TF-IDF/keyword) + SVM (kernel RBF) + Grid Search, split 80/20, dataset PhiUSIIL.

Klaim & celah yang langsung terlihat:

- Diusulkan untuk “real-time URL screening / browser extension”.
- Kode men-drop kolom URL → fitur NLP yang diklaim tak masuk model.
- Tanpa cross-validation & tanpa baseline terkontrol; sejumlah inkonsistensi internal.

Research Gap (terbukti empiris)

4

G1

Benchmark saturation

Hampir semua subset fitur (bahkan URL mentah) $\geq 99.7\%$.
99.99% = sifat dataset, bukan keunggulan metode.

G2

NLP tak terisolasi

Setelah diisolasi, NLP cuma +0.1% in-distribution. Bukan driver performa seperti diklaim.

G3

Tanpa uji generalisasi

Tak ada studi PhiUSIIL yang menguji ke dataset phishing berbeda — skenario deployment nyata.

Novelty & Pendekatan

5

N1

Demonstrasi saturasi — ablation lintas subset fitur

N2

Protokol cross-dataset + asimetri — ukur generalisasi nyata ($D1 \leftrightarrow D2$)

N3

Isolasi NLP → arah konstruktif — char-level = sinyal transferable

Bingkai akhir

Kritik + arah konstruktif: fitur leksikal/konten menyesatkan; representasi level-karakter URL yang lebih generalizable.

Metode: Protokol Cross-Dataset

D1 — PhiUSIIL

235.795 URL
(UCI 967)

D2 — PhishDataset

20.000 URL
(Aung & Yamana)

Ekstraktor identik

- 22 fitur leksikal URL
- char n-gram TF-IDF (3–5)
- SVM, RF, LogReg
- scaler fit di train saja

Tiga evaluasi

- In-distribution: train+test PhiUSIIL (split + 5-fold CV)
- Cross-dataset: train D1 → test D2
- Reverse: train D2 → test D1 (asimetri)

Hasil 1 — Saturasi Benchmark

7

Feature set (SVM)	Acc	AUC
FULL (50, = paper)	0.9999	1.000
minus URLSimilarityIndex	0.9998	1.000
URL-only (pre-visit)	0.9966	0.998
NLP-only (char n-gram)	0.9978	0.999


≈ 99.7%+

apa pun subset fiturnya. Karena semua menang, “peningkatan metode” tak teridentifikasi = noise.

Hasil 2 — Runtuh Cross-Dataset

8

Generalization gap: ~99% in-distribution collapses to chance cross-dataset




99% → ~50%

Model 99.x% di PhiUSIIL
turun ke tebak-acak di
dataset phishing lain. Akurasi
in-distribution ≠ skill nyata.

Hasil 3 — Asimetri = Sampling Bias

9

Asymmetry: easy benchmark teaches non-transferable shortcuts




- Train D2 → PhiUSIIL: 90%
- Train PhiUSIIL → D2: 50%

PhiUSIIL mengajari shortcut yang tidak transfer; dataset realistis mengajari sinyal yang transfer.

Hasil 4 — Char-level Satu-satunya yang Transfer

10

ROC: lexical fails cross-dataset, char n-gram retains ranking



AUC 0.94 cross-dataset

- Fitur leksikal/struktural runtuh (AUC 0.50–0.79).
- Char n-gram URL mempertahankan ranking lintas-dataset.
- Arah: subword/transformer URL + kalibrasi threshold.

Kesimpulan

- Akurasi ~100% di PhiUSIIL = separabilitas dataset, bukan skill phishing-detection.
- Model PhiUSIIL gagal total ($\approx 50\%$) di dataset independen; transfer sangat asimetris.
- Representasi level-karakter URL satu-satunya yang generalize.
- Rekomendasi: cross-dataset evaluation jadi standar; eksplor subword/transformer + kalibrasi + domain adaptation.

Kontribusi: kritik yang jujur + arah konstruktif, dengan protokol cross-dataset yang reproducible.